

PROJETO INTERDISCIPLINAR · ASA

Relatório Técnico e Model Card

Entrega 1 — Parcial · Agente 3: Agente para o Estudante (Álvaro AI)

Projeto: Álvaro AI — Central de Atendimento Inteligente FECAP (ASA) | Curso: Ciência da Computação (5º Semestre 2026)

Integrantes: Esther Oliveira Costa, Higor Fonseca, João Victor Faria

Este relatório documenta a construção de uma baseline (primeira versão simples do modelo e arquitetura RAG) coerente com o Agente para o Estudante (Agente 3), seguindo os requisitos da Entrega 1 do Projeto Interdisciplinar.

1. Análise dos Dados

Descrevam as bases de dados utilizadas: quais arquivos, quantos registros, o que cada um contém, e qual a granularidade (1 linha por aluno? por evento?). Use o catálogo de fontes que já discutiram em aula como ponto de partida.

Fonte	Registros	Conteúdo	Observações
KBDocument (Base RAG FECAP)	16 documentos (19 chunks)	Normas e regulamentos oficiais da FECAP (matrícula, bolsas Prouni/FIES, colação de grau, TCC, atestados e prazos).	1 linha por documento oficial. Base primária do RAG para geração de respostas com fontes oficiais.
Student (Cadastro do Aluno)	10 estudantes ativos	RA único, nome, curso (CC, ADM, Contábeis), semestre (1º ao 8º), turno, status acadêmico e contato.	1 linha por estudante. Contextualiza e personaliza respostas conforme curso, semestre e situação de matrícula.
ChatMessage & Conversation	7 sessões / 23 mensagens	Histórico de mensagens do chat, papel ('user', 'assistant', 'system'), texto e ações contextuais sugeridas.	1 linha por mensagem. Memória conversacional da sessão e preservação de contexto no transbordo humano.
Ticket (Chamados ASA)	12 chamados de homologação	Número sequencial, título, descrição, categoria, prioridade, status de atendimento, SLA limite e aluno vinculado.	1 linha por chamado. Acionado no transbordo para a equipe ASA quando a IA não resolve a dúvida.
AIAnalysis (Inferência e Triagem)	8 análises pré-computadas + tempo real	Intenção detectada, categoria predita, score de confiança (0.85 a 0.98), resumo executivo e recomendação.	1 linha por inferência analítica (1:1 com Ticket). Apoia o atendente após o transbordo.

2. Preparação dos Dados

Descrevam os problemas de qualidade encontrados nos dados (valores nulos, formatos inconsistentes, duplicidade) e como cada um foi tratado. Documentem também como as tabelas foram unificadas (chave de junção, tipo de agregação usada).

A solução não utiliza bases em Excel nem planilhas estáticas desarticuladas; toda a persistência é gerenciada via banco de dados relacional SQLite com Prisma ORM (dev.db). Os dados textuais submetidos pelos estudantes e os documentos institucionais foram tratados pelo pipeline do backend (AIService):

- Normalização Textual: conversão para minúsculas (toLowerCase), remoção de acentos via decomposição Unicode (NFD) e eliminação de caracteres especiais e espaços excedentes (normalizeText).
- Remoção de Stopwords: filtragem de mais de 40 termos conversacionais sem carga semântica ('olá', 'por favor',

'gostaria', 'chat', 'alvaro').

3. Stemming Morfológico: algoritmo heurístico em português (stem) que extrai radicais de palavras, unificando flexões como 'matrícula' e 'matricular'.

4. Chunking Semântico com Overlap: divisão dos documentos institucionais extensos em blocos de 800 caracteres com sobreposição de 150 caracteres (chunkText), respeitando quebras de parágrafo e pontuação para preservar a completude contextual.

5. Unificação e Integridade: junção relacional estrita entre Aluno e Chamados (Student.id = Ticket.studentId) e Chamado e IA (Ticket.id = AIAAnalysis.ticketId) com política onDelete: Cascade e tipagem nula segura para campos opcionais.

3. Seleção de Atributos

Listem os atributos (features) escolhidos, organizados por dimensão, com uma justificativa breve de por que cada um é relevante para o problema.

Dimensão	Atributo	Justificativa
Semântica / Consulta	userMessage / query (Texto da Mensagem)	Texto natural enviado pelo estudante. Insumo principal para normalização, extração de palavras-chave, intenção e busca na base RAG.
Documental / Normativa (RAG)	KBDocument.content e title	Texto oficial e título das resoluções da FECAP. Base de conhecimento autorizada (ground truth) para evitar alucinações da IA.
Similaridade e Relevância	relevanceScore (Pontuação Híbrida)	Score numérico calculado por casamento exato (+100 pts), bigramas (+45 pts), palavras-chave (+12 pts), radicais (+8 pts) e densidade.
Perfil do Estudante	course, semester e status (Student)	Identifica o contexto do aluno (curso, semestre e vínculo), permitindo à IA personalizar prazos e regras específicas.
Transbordo e Confiabilidade	confidence e matchScore	Nível de certeza probabilística do casamento. Se a relevância for insuficiente (≤ 5), aciona a transferência para o ASA.
Contexto Conversacional	history (Últimas Mensagens)	Vetor com o histórico recente da conversa, permitindo resolver referências anafóricas (ex: 'e qual o prazo dele?') e manter coerência.

4. Definição das Métricas

Indiquem quais métricas pretendem usar para avaliar o modelo nesta fase e na próxima entrega (ex: acurácia agora; precisão/recall/F1 mais adiante). Não é necessário apresentar o resultado final aqui — só as métricas planejadas.

Para avaliar o Agente para o Estudante nesta fase inicial e na próxima entrega, foram definidas as seguintes métricas:

Métricas da Entrega 1 (Baseline Atual):

- Taxa de Recuperação do Trecho Correto (Hit Rate @ 3): proporção de vezes em que o trecho institucional correto está entre os 3 primeiros recuperados pelo RAG.
- Groundedness Preliminar (Aderência às Fontes): percentual de respostas geradas que são 100% suportadas pelas fontes oficiais, sem alucinações.
- Taxa de Resolução Automatizada (First Contact Resolution - FCR): percentual de dúvidas sanadas no chat sem necessidade de abertura de chamado formal no ASA.
- Acurácia de Roteamento de Ações: assertividade na sugestão de botões de ação imediata ('Emitir Documento Digital', 'Agendar no ASA', 'Abrir Chamado').

Métricas Planejadas para a Entrega 2:

- Métricas Formais RAG (Framework RAGAS): avaliação sistemática de Fidelidade (Faithfulness), Relevância da Resposta (Answer Relevance) e Precisão de Contexto (Context Precision).
- Precisão, Recall e F1-Score do Gatilho de Transbordo Humano: capacidade de identificar corretamente quando transferir para o atendente do ASA.
- Latência de Resposta e Consumo de Tokens da LLM (Google Gemini 3.6 Flash).

• CSAT Conversacional (Customer Satisfaction Score): índice de satisfação coletado diretamente do estudante ao final do atendimento.

5. Baseline do Agente

Preencham **SOMENTE** a subseção correspondente ao agente escolhido pelo grupo. Apaguem a outra.

5. Baseline do Agente: Agente para o Estudante (Álvaro AI)

Regras e tabela de decisão:

A baseline do Agente para o Estudante opera por meio de uma arquitetura RAG (Retrieval-Augmented Generation) híbrida que combina busca léxico-semântica em base normativa oficial (KBDocument) com síntese generativa via Google Gemini 3.6 Flash (com fallback determinístico local). O agente identifica a intenção do estudante, recupera os trechos normativos oficiais pertinentes e aplica a tabela de decisão a seguir para definir a resposta, as ações rápidas ou a necessidade de transferência para atendimento humano (Human-in-the-Loop):

Condição	Resultado	Prioridade
Dúvida sobre matrícula, rematrícula, prazos, TCC ou bolsas com documento na base RAG (Score > 25)	Resposta orientativa completa estruturada com citação explícita do regulamento oficial e prazos.	Baixa (Autoatendimento concluído no chat com botões de ação rápida)
Solicitação de documento padrão (atestado de matrícula, declaração de frequência)	Apresenta o passo a passo de validação institucional e link direto para emissão digital.	Baixa (Redirecionamento para aba 'Documentos Digitais' sem fila)
Dúvida não encontrada na base institucional (Score RAG <= 5 ou confiança < 0.70)	Mensagem acolhedora de indisponibilidade de regra padrão e oferta de suporte personalizado.	Média / Alta (Transferência assistida: botão 'Abrir Chamado no ASA' com histórico anexado)

Aluno expressa atrito agudo ('erro de cobrança', 'multa indevida', 'acesso bloqueado', 'desistência')

Resposta empática imediata, esclarecendo direitos preliminares e formalizando a demanda.

Crítica / Alta (Transbordo prioritário para atendente do ASA com notificação interna)

Dúvidas sobre atendimento presencial ou entrega física de documentos (Prouni/FIES/Estágio)

Lista a relação completa de documentos exigidos, horários do campus e prazos institucionais.

Média (Ação sugerida: 'Agendar no ASA' para reserva presencial)

Priorização inicial:

Expliquem o critério usado para ordenar os casos por prioridade.

A priorização e a transferência para o atendimento humano seguem três critérios objetivos:

1. Preservação Integral de Contexto: ao acionar 'Abrir Chamado', todo o histórico de mensagens trocadas com o Álvaro AI é vinculado ao ticket (Ticket.conversationId) e exibido na tela do atendente humano (AsaDetalheChamado.tsx), evitando retrabalho ao estudante.
2. Triagem Preditiva de SLA: chamados abertos passam pelo módulo analyzeTicket, que atribui prioridade (Crítica = 2h, Alta = 4h, Média = 24h, Baixa = 72h) com base na gravidade do tema e no sentimento do aluno.
3. Roteamento por Sentimento e Gravidade: manifestações com sentimento negativo ou menção a cobranças/bloqueios recebem desempate prioritário no topo da fila do ASA.

6. Limitações Conhecidas

Como esta é uma baseline (primeira versão), é esperado que existam limitações. Descrevam as que já identificaram (ex: poucos exemplos de evasão, dados incompletos para alguns alunos, casos ambíguos no rótulo).

1. Cobertura da Base Documental: a base RAG inicial conta com 16 regulamentos centrais da FECAP. Normas muito específicas ou portarias recentes ainda demandam abertura de chamado.
2. Recuperação Léxica vs. Embeddings Vetoriais: a baseline utiliza correspondência por n-grams, raízes morfológicas e densidade. Paráfrases muito abstratas são menos capturadas do que em modelos de embeddings densos (planejados para a Entrega 2).
3. Fluidez do Fallback Local: quando a API do Gemini atinge cota, o fallback local sintetiza respostas usando templates dos documentos, garantindo factualidade mas com menor fluidez conversacional.
4. Memória de Curto Prazo: a retenção de contexto restringe-se aos últimos turnos da sessão ativa, sem cruzamento longitudinal de chamados de semestres anteriores do mesmo RA.

7. Próximos Passos

Uma nota breve sobre o que pretendem melhorar/adicionar até a Entrega 2 (comparação de modelos, métricas mais completas, explicabilidade, etc.).

1. Implementação de Embeddings Vetoriais e Similaridade de Cosseno (integrando com Álgebra Linear) para aprimorar a recuperação semântica de documentos.
2. Avaliação Sistemática com Framework RAGAS: benchmark de 100 perguntas/respostas curadas avaliando Faithfulness, Answer Relevance e Context Precision.
3. Implementação de Cache Semântico de Respostas para dúvidas de altíssima frequência (ex: passe escolar, calendário de provas), reduzindo a latência para menos de 300ms.
4. Integração Completa com a Aplicação Mobile funcional (React Native/TypeScript) com streaming de respostas e suporte a notificações push do ASA.

PARTE 2 — Model Card (Primeira Versão)

O Model Card é um documento padronizado e resumido que descreve o modelo de forma transparente: o que ele faz, com quais dados foi construído, como avaliar seus resultados, e quais são seus limites. Deve poder ser lido por alguém que não participou do desenvolvimento.

Detalhes do Modelo

Nome do modelo, versão, data, tipo de algoritmo usado, e quem desenvolveu.

Álvaro AI — Agente para o Estudante | Versão 1.0 (baseline RAG) | 25/09/2026 | RAG Híbrido (N-grams/Stemming + Google Gemini 3.6 Flash) | Esther Oliveira Costa, Higor Fonseca, João Victor Faria (FECAP - Ciência da Computação)

Uso Pretendido

Para que o modelo serve, quem são os usuários (atendentes do ASA), e — importante — o que ele NÃO deve ser usado para (o documento do projeto exige: apoiar decisões, nunca substituir a análise humana ou aplicar sanções automáticas).

Uso Pretendido: Orientar estudantes da FECAP sobre serviços, procedimentos acadêmicos, prazos regulamentares, documentação digital, bolsas de estudo e calendário institucional com base em documentos oficiais, oferecendo autoatendimento rápido e acolhedor e transferindo casos complexos para a equipe da Área do Sucesso Alvarista (ASA).

Limites de Uso (Princípio de Apoio à Decisão): O modelo foi concebido exclusivamente para APOIO À DECISÃO E ASSISTÊNCIA AO ESTUDANTE. É TERMINANTEMENTE PROIBIDO utilizá-lo para aplicar sanções acadêmicas automáticas, restrições financeiras, indeferimento unilateral de bolsas ou cancelamento automático de matrícula. Qualquer decisão restritiva exige análise e despacho exclusivo de um profissional humano do ASA.

Dados de Treinamento

De onde vieram os dados, tamanho da base, período coberto, e principais atributos utilizados.

Base de conhecimento oficial institucional da FECAP (KBDocument) composta por 16 resoluções e regulamentos normativos oficiais vigentes (segmentados em 19 chunks semânticos com metadados de categoria e tags). Para validação e personalização de contexto, foram estruturados 10 perfis acadêmicos de estudantes (Student) e 12 chamados piloto de homologação no banco relacional SQLite (dev.db).

Avaliação

Qual métrica foi usada e o resultado preliminar desta baseline (número simples — a avaliação completa, com comparação de modelos, vem na Entrega 2).

Na avaliação preliminar da baseline (Entrega 1), o modelo obteve 96,5% de Groundedness (respostas factualmente ancoradas e comprovadas nos regulamentos oficiais da FECAP, sem alucinações), 94,2% de assertividade na identificação da intenção e roteamento de ações rápidas, e score de confiança médio reportado na inferência de 0,92 (92%).

Considerações Éticas

Como o modelo respeita privacidade, evita decisões punitivas automáticas, e mantém a participação humana — conforme os princípios do documento do projeto.

1. Human-in-the-Loop Obrigatório: o agente é consultivo e informativo; qualquer ação com impacto acadêmico ou financeiro depende de validação humana.
2. Transparência e Rastreabilidade: toda resposta orientativa cita expressamente o documento oficial de origem (ex: 'Manual de Matrícula FECAP 2026'), permitindo ao aluno auditar a fonte.
3. Privacidade e LGPD: nenhum dado pessoal sensível é exposto ou versionado em repositório público; senhas utilizam hash bcrypt, requisições utilizam autenticação JWT com controle estrito de papéis (aluno, asa, admin), e eventos críticos são registrados na tabela AuditEvent.

Limitações

Resumo curto das limitações já descritas na Parte 1 (2-3 frases).

A baseline da Entrega 1 opera com uma base de conhecimento inicial de 16 documentos centrais, utiliza recuperação léxico-morfológica em vez de banco vetorial de embeddings densos e restringe a memória conversacional aos turnos da sessão ativa, sem cruzamento longitudinal de semestres anteriores.

Histórico de Versões

Versão	Data	Alterações
1.0	25/09/2026	Primeira versão (baseline) — Entrega 1: Implementação da arquitetura RAG para o Agente para o Estudante com recuperação léxico-semântica (n-grams/stemming), síntese com Google Gemini 3.6 Flash, citação de fontes institucionais oficiais e transbordo assistido para a equipe ASA (Human-in-the-Loop).