

PROJETO INTERDISCIPLINAR · ASA

Relatório Técnico e Model Card

Entrega 1 — Parcial · Agente de Monitoramento de Estudantes

Esther Oliveira Costa – Higor Fonseca – João Victor de Faria

Este relatório documenta a construção de uma baseline (primeira versão simples do modelo) coerente com o agente escolhido, seguindo os requisitos da Entrega 1 do Projeto Interdisciplinar.

1. Análise dos Dados

Descrevam as bases de dados utilizadas: quais arquivos, quantos registros, o que cada um contém, e qual a granularidade (1 linha por aluno? por evento?). Use o catálogo de fontes que já discutiram em aula como ponto de partida.

Fonte	Registros	Conteúdo	Observações
Contato.xlsx	1 linha/aluno (cadastro)	ID_ALUNO, Idade, Bairro/Cidade/Estado, Estado Civil, Sexo	Chave de junção de todas as tabelas; 4 alunos com Estado Civil nulo foram removidos
Matriculas.xlsx	1–2 linhas/aluno	Período Letivo, Forma de Ingresso, Curso/Grau Acadêmico/Turno, Status Acadêmico	Coluna 'Risco de Evasão' vem 100% zerada e não foi usada; Status Acadêmico é a base do rótulo evadiu
Historico.xlsx	1 linha/disciplina cursada por semestre	Ano/Semestre, Disciplina, Situação, % Nota, % Assiduidade, Faltas	Usada para média de notas/assiduidade e tendência (2 últimos semestres vs 2 primeiros)
Financeiro.xlsx	1 linha/parcela financeira	Parcela, BolsaAluno, Valor, StatusLancamento, datas de vencimento/baixa	Base da dimensão financeira (pct_parcelas_em_aberto, atraso_medio_dias, valor_total_periodo etc.)
Relacionamentos.xlsx	1 linha/atendimento do ASA	Tema, Motivo do Contato, Motivo da Evasão, Alternativa de Permanência, Data	Motivo da Evasão e Tema='Risco de Evasão' excluídos das features (só existem após a evasão → vazamento de dado)
Base unificada (base_unificada_asa-final.csv)	12.842 alunos (1 linha/aluno)	23 atributos agregados em 5 dimensões + rótulo evadiu	Resultado do notebook de unificação; taxa de evasão de 19,6% (2.512 de 12.842)

2. Preparação dos Dados

Descrevam os problemas de qualidade encontrados nos dados (valores nulos, formatos inconsistentes, duplicidade) e como cada um foi tratado. Documentem também como as tabelas foram unificadas (chave de junção, tipo de agregação usada).

Filtramos primeiro para manter só alunos de ensino superior (Bacharelado, Tecnólogo, Pós-Graduação), já que Financeiro, Historico e Relacionamentos não cobrem Ensino Médio/Técnico. A coluna "Risco de Evasão" de Matriculas está 100% zerada, então construímos o rótulo evadiu a partir de Status Acadêmico: Cancelado/Trancado/Transferência Externa/Ausente = evadiu (1); Formado/Matriculado/Aprovado/Concluído/Pré-Matriculado = não evadiu (0); casos ambíguos (Aguardando Rematrícula, Transferência Interna, Reprovado) foram excluídos da base para não introduzir ruído no rótulo. As 4 tabelas de evento (Matriculas, Historico, Financeiro, Relacionamentos) foram agregadas por groupby(ID_ALUNO), 1 linha por tabela por aluno, e depois unidas com merge (how="left") usando ID_ALUNO como chave. Nulos residuais (alunos sem nenhum registro em

Financeiro/Historico/Relacionamentos, ex.: recém-matriculados) foram preenchidos com 0 nas numéricas — ausência de atividade — e mantidos como categoria própria nas categóricas. Ainda restaram 4 alunos com Estado Civil nulo em Contato, removidos com dropna() por serem poucos (4 de 12.846). Base final: 12.842 alunos, 1 linha por aluno, taxa de evasão de 19,6%.

3. Seleção de Atributos

Listem os atributos (features) escolhidos, organizados por dimensão, com uma justificativa breve de por que cada um é relevante para o problema.

Dimensão	Atributo	Justificativa
Financeira	pct_parcelas_em_aberto, pct_parcelas_acordo, atraso_medio_dias	Sinais diretos de dificuldade financeira, um dos motivos mais comuns de evasão
Financeira	tem_bolsa, valor_total_periodo, total_parcelas	Contexto do compromisso financeiro do aluno com a instituição
Acadêmica	media_notas, media_assiduidade, pct_reprovacao	Desempenho acadêmico é preditor clássico de evasão
Acadêmica	tendencia_notas, tendencia_assiduidade, total_semestres	Captura se o aluno está piorando/melhorando ao longo do curso, não só o nível absoluto
Relacionamento	total_contatos, dias_desde_ultimo_contato	Mede o quanto o ASA já interagiu com o aluno e há quanto tempo
Geográfica/Demográfica	mora_sp_capital, Idade, Estado Civil, Sexo	Fatores de contexto pessoal associados a risco de evasão na literatura
Contexto (matrícula)	Forma de Ingresso, Turno, tempo_de_curso	Forma de entrada e estágio no curso influenciam o vínculo com a instituição

4. Definição das Métricas

Indiquem quais métricas pretendem usar para avaliar o modelo nesta fase e na próxima entrega (ex: acurácia agora; precisão/recall/F1 mais adiante). Não é necessário apresentar o resultado final aqui — só as métricas planejadas.

Nesta Entrega 1, já comparamos os 4 algoritmos usando acurácia, precisão, recall e F1 (não só acurácia), porque a base é desbalanceada — apenas 19,6% dos alunos evadiram, então acurácia sozinha esconde o desempenho na classe minoritária (evasão), que é a que mais importa para o ASA. F1 foi o critério principal para escolher a baseline, por equilibrar precisão (evitar alarmes falsos) e recall (não deixar passar casos de risco real). Na Entrega 2 pretendemos aprofundar com matriz de confusão completa, validação cruzada e, dado o desbalanceamento, dar peso extra ao recall da classe evadiu=1.

5. Baseline do Agente

Agente escolhido pelo grupo: Agente de Monitoramento de Estudantes.

5a. Se Agente de Monitoramento de Estudantes

Score / modelo inicial:

Descrevam como o score foi calculado (ou qual modelo foi treinado), e como a classificação Verde/Amarelo/Vermelho foi definida (limiares escolhidos).

Testamos os 4 algoritmos vistos em aula sobre a mesma base unificada (12.842 alunos, 30 features após get_dummies, split 80/20 estratificado por evadiu, StandardScaler aplicado para Regressão Logística e KNN): Regressão Logística (acurácia 84,2%, F1 48,0%), KNN k=5 (acurácia 84,8%, F1 51,1%), Árvore de Decisão profundidade 6 (acurácia 88,6%, F1 69,0%) e Random Forest com 200 árvores e profundidade máxima 10 (acurácia 90,2%, precisão 85,2%, recall 60,4%, F1 70,7%). Escolhemos o Random Forest como baseline por ter o melhor F1 e a melhor precisão entre os 4. O score de risco é obtido via predict_proba() (probabilidade de evasão × 100, de 0 a 100) e classificado em Verde (score < 33), Amarelo (33–66) e

Vermelho (≥ 66) — limiares de partida sugeridos no guia do projeto, ainda não validados com a equipe do ASA. Na base de teste (2.569 alunos), a distribuição resultante foi 81,4% Verde, 9,6% Amarelo e 9,0% Vermelho.

Explicação dos fatores:

*Indiquem quais variáveis mais pesaram na decisão do modelo (ex: `feature_importances_` da *Árvore/Random Forest*, ou coeficientes da *Regressão Logística*), com uma breve interpretação.*

Pelo `feature_importances_` do Random Forest, os fatores que mais pesam na classificação são: `valor_total_periodo` (26,0%), `media_notas` (7,9%), `dias_desde_ultimo_contato` (7,4%), `pct_parcelas_em_aberto` (7,4%), `tempo_de_curso` (6,4%) e `total_parcelas` (6,0%) — ou seja, as dimensões financeira e acadêmica dominam a decisão do modelo. Um achado importante ao investigar os coeficientes da Regressão Logística: `pct_parcelas_em_aberto` teve coeficiente negativo, isto é, ter parcelas "em aberto" está associado a NÃO evadir. Ao investigar, entendemos que parcelas de quem evade tendem a ser canceladas no sistema, não ficam "em aberto" — a coluna acaba medindo em parte "ainda matriculado" e não só "dificuldade financeira". Documentamos isso como limitação (seção 6) e propomos refinar a feature na Entrega 2, por exemplo contando apenas parcelas já vencidas e não pagas em relação à data de referência.

6. Limitações Conhecidas

Como esta é uma baseline (primeira versão), é esperado que existam limitações. Descrevam as que já identificaram (ex: poucos exemplos de evasão, dados incompletos para alguns alunos, casos ambíguos no rótulo).

(1) Classes desbalanceadas: apenas 19,6% dos alunos evadiram, o que reduz o recall (60,4% no Random Forest) — o modelo ainda deixa passar boa parte dos casos de risco real. (2) O rótulo foi construído indiretamente a partir de Status Acadêmico, já que a coluna oficial "Risco de Evasão" está 100% zerada; casos ambíguos (Aguardando Rematrícula, Transferência Interna, Reprovado) foram excluídos da base. (3) 4 alunos (de 12.846) foram removidos por terem Estado Civil ausente em Contato. (4) A feature `pct_parcelas_em_aberto` tem uma limitação conceitual identificada: ela mistura "dificuldade financeira" com "ainda estar matriculado" (ver Explicação dos fatores). (5) Os limiares de score (33/66) são um ponto de partida arbitrário e ainda não foram validados com a equipe do ASA. (6) Não fizemos ainda validação cruzada nem ajuste fino de hiperparâmetros — os 4 modelos foram testados com parâmetros simples/padrão.

7. Próximos Passos

Uma nota breve sobre o que pretendem melhorar/adicionar até a Entrega 2 (comparação de modelos, métricas mais completas, explicabilidade, etc.).

Para a Entrega 2 pretendemos: (1) ajustar os limiares Verde/Amarelo/Vermelho com base nos quartis reais da distribuição do score; (2) refinar `pct_parcelas_em_aberto` para separar "em aberto e vencida" de "em aberto e dentro do prazo"; (3) fazer validação cruzada e tuning de hiperparâmetros (profundidade e nº de árvores do Random Forest, k do KNN, regularização da Regressão Logística); (4) reportar matriz de confusão completa e testar balanceamento de classes (`class_weight="balanced"` ou oversampling), dado o desbalanceamento da base; (5) aprofundar a explicabilidade (ex.: SHAP) para a versão final do Model Card.

PARTE 2 — Model Card (Primeira Versão)

O Model Card é um documento padronizado e resumido que descreve o modelo de forma transparente: o que ele faz, com quais dados foi construído, como avaliar seus resultados, e quais são seus limites. Deve poder ser lido por alguém que não participou do desenvolvimento.

Detalhes do Modelo

Nome do modelo, versão, data, tipo de algoritmo usado, e quem desenvolveu.

ASA-Monitor | Versão 1.0 (baseline) | 25/09/2026 | Random Forest (200 árvores, profundidade máx. 10) — selecionado entre 4 algoritmos testados (Regressão Logística, KNN, Árvore de Decisão, Random Forest) | [Nome do grupo — preencher]

Uso Pretendido

Para que o modelo serve, quem são os usuários (atendentes do ASA), e — importante — o que ele NÃO deve ser usado para (o documento do projeto exige: apoiar decisões, nunca substituir a análise humana ou aplicar sanções automáticas).

O modelo apoia os atendentes do ASA a priorizar quais alunos contatar primeiro, gerando um score de risco de evasão (0 a 100) e uma classificação Verde/Amarelo/Vermelho. Usuários pretendidos: equipe de atendimento e coordenação do ASA. O modelo NÃO deve ser usado para tomar decisões automáticas (ex.: cancelamento de matrícula, corte de bolsa, bloqueio de matrícula) nem para substituir a avaliação humana — ele funciona apenas como um sinal a mais para orientar o contato proativo com o aluno, nunca como sanção automática.

Dados de Treinamento

De onde vieram os dados, tamanho da base, período coberto, e principais atributos utilizados.

Base unificada a partir de 5 fontes do ASA (Contato, Matrículas, Histórico, Financeiro e Relacionamentos), agregadas por ID_ALUNO. 12.842 alunos de ensino superior (Bacharelado, Tecnólogo, Pós-Graduação), 1 linha por aluno, 23 atributos organizados em 5 dimensões (financeira, acadêmica, relacionamento, geográfica/demográfica e de contexto de matrícula) mais o rótulo evadiu, derivado do Status Acadêmico. Split 80/20 estratificado para treino/teste (30 features após codificação das categóricas com `get_dummies`).

Avaliação

Qual métrica foi usada e o resultado preliminar desta baseline (número simples — a avaliação completa, com comparação de modelos, vem na Entrega 2).

No conjunto de teste (2.569 alunos), o Random Forest obteve acurácia de 90,2%, precisão de 85,2%, recall de 60,4% e F1 de 70,7% — o melhor resultado entre os 4 algoritmos comparados nesta entrega (Regressão Logística, KNN, Árvore de Decisão e Random Forest). A avaliação completa, com validação cruzada, matriz de confusão e análise por subgrupo, fica para a Entrega 2.

Considerações Éticas

Como o modelo respeita privacidade, evita decisões punitivas automáticas, e mantém a participação humana — conforme os princípios do documento do projeto.

O rótulo evadiu foi construído a partir do Status Acadêmico institucional, sem usar informações que só existem após a evasão (Motivo da Evasão e Tema="Risco de Evasão" foram excluídos das features para evitar vazamento de dado). O modelo trabalha apenas com dados já agregados por aluno, sem expor detalhes individuais de atendimento fora do necessário. Toda classificação (Verde/Amarelo/Vermelho) deve ser tratada como apoio à decisão humana, nunca como sanção automática — a decisão final de contato e intervenção é sempre da equipe do ASA.

Limitações

Resumo curto das limitações já descritas na Parte 1 (2-3 frases).

Classes desbalanceadas (19,6% de evasão) limitam o recall do modelo; a feature pct_parcelas_em_aberto tem uma limitação conceitual (mistura sinal financeiro com matrícula ativa); os limiares de score ainda não foram validados com a ASA; e esta primeira versão não passou por validação cruzada nem tuning de hiperparâmetros.

Histórico de Versões

Versão	Data	Alterações
1.0	25/09/2026	Primeira versão (baseline) — Entrega 1