PROJETO INTERDISCIPLINAR — INTELIGÊNCIA ARTIFICIAL

Relatório Técnico | Entrega 2

Avaliação, explicabilidade, versão do conhecimento e inferência do Álvaro AI

Esther Oliveira Costa • Higor Luiz Fonseca dos Santos • João Victor de Faria Santana

Ciência da Computação | 5º semestre | São Paulo

ESCOPO EXCLUSIVO: ÁLVARO AI — AGENTE PARA O ESTUDANTE

Relatório final com evidências funcionais e benchmark demonstrativo reproduzível.

Resumo executivo

O Álvaro AI oferece atendimento acadêmico em linguagem natural à comunidade estudantil da FECAP, combinando recuperação de documentos institucionais (RAG), geração de respostas com modelo Gemini configurável e síntese local alternativa. A solução registra conversas, recomenda ações e pode transferir a demanda para atendimento humano do ASA com o histórico preservado.

Esta entrega reúne: (i) análise do código do repositório, (ii) comparação reproduzível de quatro estratégias de recuperação em corpus fictício controlado, (iii) avaliação visual de três fluxos observados no sistema, (iv) explicabilidade, riscos e análise de abstenção, (v) código adicional de inferência versionada e (vi) Model Card individualizado.

Delimitação metodológica: os números quantitativos deste relatório são medições REAIS da execução do algoritmo de avaliação em dados SINTÉTICOS; não são resultados de produção nem equivalem à precisão factual das respostas do Gemini. As oito evidências visuais foram fornecidas pelo grupo; o endpoint novo está preparado em patch, ainda não implantado.

Quadro de resultados

Dimensão	Evidência apurada	Escopo da comprovação
Demonstração funcional	3 cenários observados em 8 capturas	Interface: consulta, abstenção e chamado #1064
Benchmark de recuperação	36 questões, 6 documentos fictícios; 13 questões no teste	Experimento offline sintético
Comparação de métodos	4 configurações; Hit@1/3, MRR/nDCG, cobertura, F1	Avaliação do recuperador, não de respostas geradas
Teste unitário de abstenção	5 testes executados e aprovados (Node.js)	Regra experimental isolada
Implantação de nova rota	Patch POST /api/ai/infer preparado	Não instalada nem homologada no GitHub principal

1. Escopo, objetivo e fontes

Objetivo: apresentar a evolução técnica e a avaliação do agente destinado a orientar estudantes sobre procedimentos acadêmicos e encaminhar dúvidas não resolvidas ao ASA. Este trabalho NÃO trata de avaliação de risco de evasão nem utiliza os experimentos do ASA-Monitor.

Fontes utilizadas: (a) arquivos da Entrega 1 do Álvaro AI fornecidos pelo grupo; (b) repositório github.com/estherolvr/Projeto-PI-5CCOMP, branch main, revisado em 06/11/2026; (c) oito telas de demonstração fornecidas pelo grupo; (d) execução de script de benchmark e testes locais em 06/11/2026. Os documentos institucionais privados e os logs de produção não foram extraídos.

Conforme o relatório anterior, a baseline utilizava 16 documentos institucionais repartidos em 19 trechos. Essa é uma contagem histórica informada na Entrega 1; o volume atual do banco conectado à aplicação pode ter mudado.

2. Arquitetura do agente e baseline

Camada	Implementação identificada no código	Papel
Interface	Frontend React/TypeScript; AlunoChat e abertura de chamados	Consulta, fontes, ações e feedback
Backend	Express/TypeScript e rotas /api/chat e /api/knowledge-base	Autenticação e orquestração
Recuperação	AIService.searchKnowledgeBase + knowledge-retrieval.ts	Seleção de documentos ativos/indexados e de passagens
Geração	GoogleGenerativeAI; variável GEMINI_MODEL; fallback local	Resposta textual em português
Dados	Prisma; Student, Conversation, ChatMessage, KBDocument, Ticket	Persistência e vínculo do atendimento
Atendimento humano	Ticket.conversationId; fila e detalhe ASA	Transferência e consulta de histórico

A recuperação usa normalização textual, remoção de termos conversacionais, radicais morfológicos e pesos para correspondências de consulta, título, categoria e tags. O algoritmo de trechos limita o contexto transmitido ao gerador. Em seu estado analisado, trata-se de busca lexical/heurística; o uso do termo “semântico” na interface não prova presença de embeddings densos.

O backend atual retorna, em determinados fluxos, constantes como confidence=0,96 ou 0,92. Esses valores são heurísticos e não representam probabilidade de correção empiricamente calibrada. O modelo Gemini é configurável; a versão empregada deve ser registrada em cada avaliação efetiva.

3. Dados, avaliação e protocolo experimental

3.1. Corpus e rotulagem

Foi preparada uma base de demonstração fictícia com seis documentos textuais institucionais genéricos e 36 perguntas rotuladas. Destas, 24 possuem referência documental designada; 12 são perguntas fora da cobertura. Os textos fictícios não representam normas reais da FECAP e não devem ser usados para orientar alunos.

A avaliação divide as 36 perguntas em 23 exemplos de validação e 13 exemplos de teste retido, com estratificação por necessidade de abstenção e semente 42. Os limiares são ajustados apenas no grupo de validação; o grupo de teste é usado posteriormente para o quadro final. Perguntas semanticamente duplicadas precisariam ser agrupadas antes do split em uma avaliação institucional mais exigente.

Versão do benchmark: 2.0.0-candidate. SHA-256 do corpus de demonstração: 88b29f62628cced31f8f125c70ee3359043e6e67b655d365b816fd03a84c1e7c. A versão da base real precisará de registro separado.

3.2. Estratégias comparadas

Estratégia	Definição	Observação
Lexical aproximada	Pontuação por palavras, raízes e bônus de título	Aproxima a lógica da baseline TypeScript, sem reproduzi-la bit a bit
TF-IDF palavras	Unigramas/bigramas; similaridade do cosseno	Dependência da sobreposição textual
TF-IDF caracteres	N-gramas de 3–5 caracteres; cosseno	Tolerância maior a variações superficiais da escrita
Híbrida	35% lexical aproximada + 65% TF-IDF caracteres	Configuração experimental; não implantada no chat

3.3. Métricas e critérios

Hit@1 e Hit@3 identificam a presença do documento de referência no primeiro resultado ou entre os três melhores. MRR@3 dá peso à posição do primeiro documento correto; nDCG@3 representa qualidade de ordenação com relevância binária. Cobertura de resposta é o percentual de perguntas que ultrapassam o limiar de evidência. Para a abstenção (classe positiva = pergunta sem fonte suficiente), calculam-se precisão, recall e F1. “Resposta sem evidência” conta a proporção global de perguntas fora da cobertura para as quais o sistema não se absteve.

O limiar de cada método foi selecionado por F2 da abstenção no conjunto de validação, priorizando a detecção de perguntas que não deveriam receber resposta institucional. O ajuste dessa política não confere capacidade automática de verificar groundedness de uma resposta gerada.

4. Resultados quantitativos — CORPUS SINTÉTICO

Os resultados abaixo foram efetivamente calculados pelo script avaliacao/avaliar_rag.py sobre a fixture indicada. São válidos apenas para esse conjunto fictício e reduzido; não podem ser apresentados como métricas de desempenho do Álvaro AI em produção.

Configuração	Hit@1	Hit@3	MRR@3	Cobertura	F1 abst.	Sem evid.
Lexical aproximada	77.8%	100.0%	0.870	46.2%	72.7%	0.0%
TF-IDF palavras	100.0%	100.0%	1.000	46.2%	72.7%	0.0%
TF-IDF caracteres	100.0%	100.0%	1.000	76.9%	85.7%	7.7%
Híbrido lexical + caracteres	100.0%	100.0%	1.000	69.2%	100.0%	0.0%

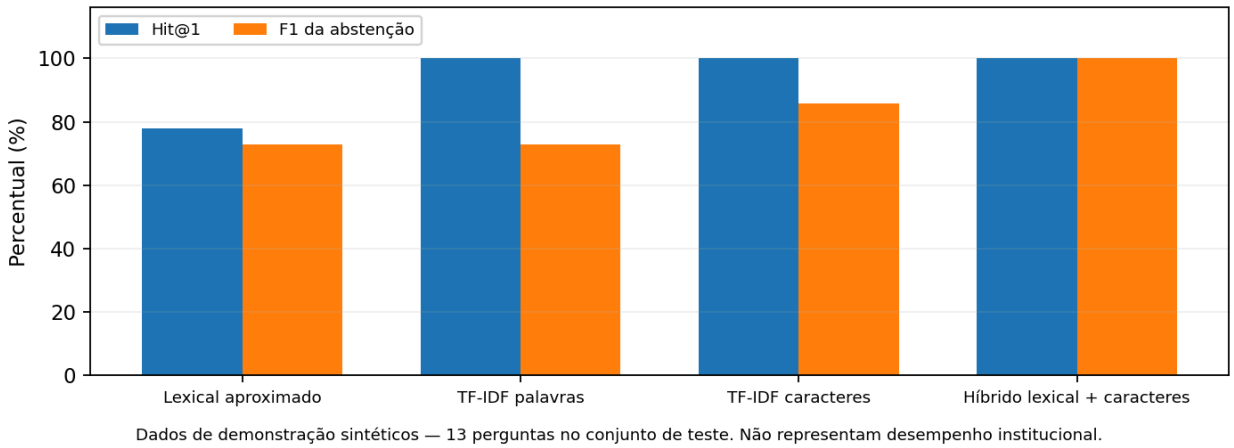


Figura 1 — Comparação experimental com base sintética. O tamanho de teste é n=13; não extrapolar para estudantes da FECAP.

No experimento, o híbrido obteve Hit@1=100%, Hit@3=100%, F1 de abstenção=100% e cobertura de 69,2%. Os 13 casos de teste incluem 9 questões cobertas e 4 fora do escopo; a configuração híbrida respondeu às 9 cobertas e se absteve diante das 4 sem cobertura. Esse resultado é insuficiente para afirmar desempenho em produção, mas permite verificar a implementação da avaliação.

A TF-IDF de caracteres também recuperou todas as fontes corretas em primeiro lugar, porém não se absteve em uma das quatro perguntas sem referência, gerando taxa global de 7,7% de resposta sem evidência (1 de 13). A estratégia lexical aproximada se absteve em todos os casos fora do escopo, mas também em três questões documentadas, reduzindo sua cobertura para 46,2%.

Seleção experimental: híbrido lexical+caracteres, por melhor equilíbrio entre recuperação, cobertura e abstenção na fixture. Seleção operacional: manter a baseline existente até repetir o benchmark com documentos autorizados, supervisão humana, versões congeladas e comparação com a implementação exata TypeScript.

5. Análise de erros e de casos concretos

Caso	Evidência	Diagnóstico
Pergunta sem fonte (fixture)	A TF-IDF caracteres respondeu a 1/4 perguntas fora do escopo	Risco de associação espúria; elevar/corrigir limiar de evidência
Abstenção excessiva (fixture)	Lexical aproximada absteve-se em 3 perguntas cobertas	Cobertura baixa; investigar paráfrases e vocabulário
Consulta prazo do PI (tela)	Resposta apresentou título de documento e datas	Conferência de data vigente depende do regulamento original
Rodapé de fontes (tela)	Título “Fontes Consultadas” repetido	Possível repetição de renderização, a investigar no frontend
Triagem do chamado (tela)	Resumo não identifica prazo exato; chat o exibe	Possível diferença entre contexto de busca, versões ou triagem

Os logs CSV entregues preservam, por pergunta, o ID do documento esperado, top-3 recuperados, escore, decisão de abstenção e sinalizações de erro. Falhas devem ser agrupadas em: base ausente/desatualizada; sinônimos e gírias; ambiguidade; contexto conversacional; inconsistência entre módulos; erro de geração; uso indevido de anexos. Nenhuma causa específica deve ser declarada como comprovada sem análise dos registros e dos textos originais.

6. Explicabilidade e rastreabilidade

A explicação do Álvaro AI deve mostrar a origem institucional de cada orientação: documento, categoria, versão, posição no ranking e trecho textual que sustenta a informação. Para recusas, a saída precisa indicar se não houve documento correspondente ou se o escore não atingiu o limiar. Essas evidências permitem que o atendente confira a resposta antes de orientar o estudante.

O score lexical mede correspondência textual, não a probabilidade de resposta correta. Consequentemente, a confiança de interface e a relevância de recuperação não devem ser denominadas “precisão do modelo” ou “garantia de fidelidade”. A fidelidade factual (groundedness) exige auditoria das afirmações contra trechos oficiais, por rubrica humana ou protocolo validado.

7. Viés, equidade, limiares e abstenção

A distribuição dos documentos e a maneira como os alunos escrevem podem causar tratamento desigual: temas com maior cobertura normativa são recuperados com facilidade, enquanto cursos menos documentados, termos coloquiais, erros de digitação e consultas com múltiplas etapas podem receber respostas inferiores. Para medir equidade sem expor dados pessoais, recomenda-se comparar Hit@3, cobertura, taxa de abstenção indevida e groundedness por tema e estilo linguístico, com amostras adequadas por subgrupo.

Risco	Medida de contenção	Condição de abstenção
Fonte inexistente ou fraca	Limiar de evidência ajustado em validação	Nenhum documento relevante ou escore abaixo do corte
Norma em conflito / data incerta	Exigir conferência da versão e do documento original	Informação incompatível ou sem trecho suficiente
Situação individual de cobrança, bolsa ou matrícula	Transbordo ao ASA com contexto preservado	Necessidade de decisão humana ou verificação cadastral
Indisponibilidade de Gemini	Fallback local com aviso explícito	Não presumir que resposta gerativa foi executada
Injeção de instruções em PDFs/anexos	Tratar documentos do usuário como dados não confiáveis	Instrução adversarial ou pedido incompatível com norma

No patch de inferência versionada, AI_RAG_MIN_SCORE=25 é provisório na escala interna do backend. Não é o mesmo que 0,175089 da composição normalizada calculada no experimento Python. Não se deve transferir esse limiar numérico entre os dois mecanismos.

8. Versionamento e endpoint de inferência

O código-base usa POST /api/chat/conversations/:id/messages para atender ao estudante e GET /api/knowledge-base/search para consulta autenticada. O pacote adicional entregue propõe POST /api/ai/infer, com autenticação, decisão explícita de abstenção, fonte/score, pipelineVersion e kbVersion calculada por SHA-256 do conteúdo e metadados relevantes dos documentos ativos.

A nova rota foi escrita em arquivos TypeScript locais e sua política passou por cinco testes unitários isolados (cinco aprovados, zero falhas). Não foi feita publicação do endpoint nem conexão dele ao frontend em produção. A branch “entrega2-alvaro-inferencia-e-avaliacao” foi criada, mas a gravação dos arquivos foi recusada e a branch não contém essa implementação.

Campo da API proposta	Descrição
status	respondido | abstencao
answer	Orientação ou recusa explicativa
sources	ID, título e pontuação das fontes localizadas
evidenceScore	Escore bruto da busca; evidenceScoreIsProbability=false
pipelineVersion	Versão declarada da lógica de inferência
kbVersion	Hash SHA-256 do conteúdo ativo consultado
requiresHumanReview	Indica encaminhamento de exceções para revisão humana

Limitações técnicas do patch: a resposta final chama novamente a rotina de recuperação após a decisão inicial, o que pode causar divergências se a base mudar durante a requisição. Idealmente, a mesma coleção de trechos deve alimentar geração e auditoria. A rota complementar requer integração e testes HTTP autenticados e não substitui automaticamente o fluxo atual.

9. Demonstração integrada — evidência visual

As capturas fornecidas pelo grupo permitem reconstruir três cenários funcionais, documentados na ordem da navegação. Não se trata de medição independente do ambiente de produção nem de um teste de desempenho em escala.

Cenário	Sequência observada	Conclusão delimitada
FUNC-01: consulta ao PI	Pergunta coloquial → resposta detalhada → fonte nominal e ações	UI apresenta recuperação com citação; acurácia da data não auditada
FUNC-02: fora do escopo	Pergunta sobre ingredientes → aviso de Gemini indisponível → fallback e chamado	Abstenção contextual observada em um caso; sem taxa geral
FUNC-03: transbordo	Chat → formulário vinculado → confirmação #1064 → fila → histórico no ASA	Fluxo de atendimento demonstrado visualmente

No detalhe do chamado #1064, o atendente visualiza cinco mensagens anteriores. O painel de análise preditiva exibe “95%” para intenção identificada, valor que não possui calibração estatística demonstrada nos materiais. Há divergência

a investigar entre o resumo da triagem (que afirma não existir data final exata) e o texto do chatbot (que informa uma data).

10. Limitações de uso, segurança e privacidade

- Não utilizar o agente para negar bolsas, determinar elegibilidade, aplicar sanções, cancelar matrícula ou decidir prazos individualizados sem conferência institucional.
- Conservar em controle de acesso os registros de Student, Conversation, ChatMessage e Ticket; não publicar RA, nomes, e-mails ou conteúdo privado em fixtures ou GitHub.
- Versionar documentos, prompt, backend e modelo Gemini por execução. Avisos de “RAG ativo” não comprovam groundedness, disponibilidade de documentos atualizados ou acurácia.
- Logs e exemplos de perguntas precisam de base legítima e anonimização. O desempenho por tema/estilo só é interpretável com amostras suficientes.
- Os resultados sintéticos de 13 testes não sustentam intervalo de confiança preciso, conclusão de equidade ou seleção definitiva de estratégia.

11. Conclusão e situação da entrega

O Álvaro AI demonstrou visualmente os componentes essenciais de atendimento: resposta documental, abstenção por falta de base em fallback e transferência de demanda para atendente com continuidade do histórico. O benchmark complementar e o código versionado fornecem material reproduzível para cumprir a estrutura técnica acadêmica do projeto.

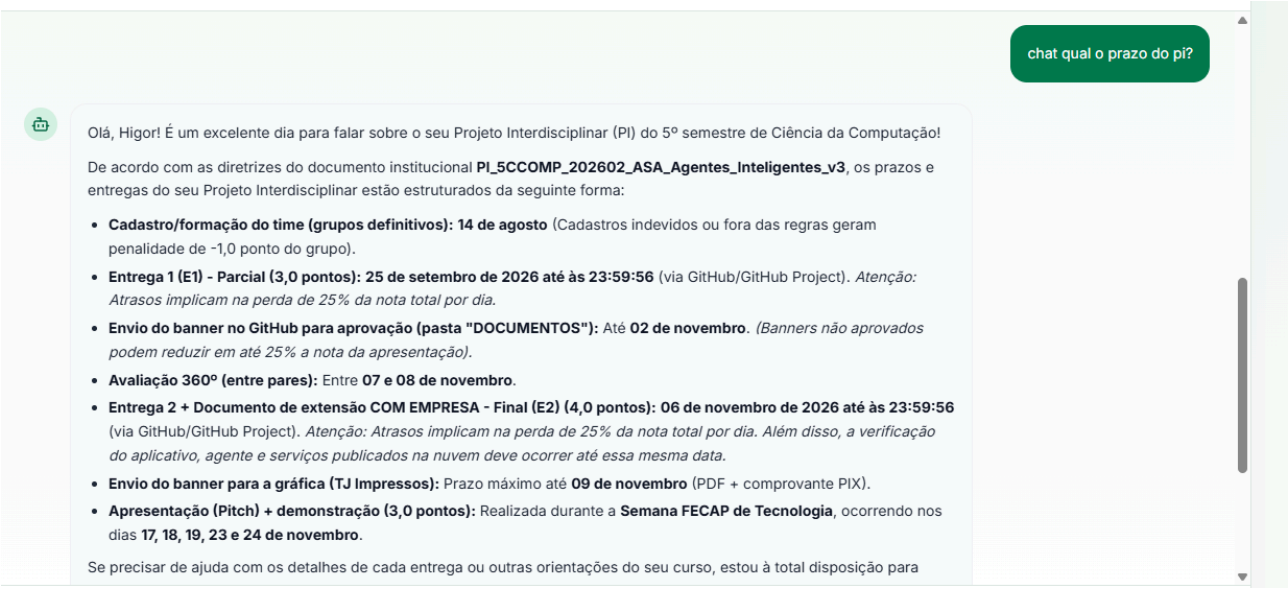
A comparação experimental foi realizada e justificada, mas sobre corpus fictício. Não se afirma validação institucional de precisão/recall/F1, groundedness, justiça entre grupos, produção do novo endpoint ou homologação pelo ASA. Esses quatro itens exigem acesso ao ambiente, um gabarito real e testes com autorização.

11.1. Matriz de atendimento aos requisitos

Critério da Entrega 2	Situação documentada
Comparação e análise de erros	Concluída no benchmark sintético; métodos e logs incluídos
Validação e métricas	Hit/MRR/nDCG/cobertura/F1 medidos em corpus sintético; produção não medida
Explicabilidade e abstenção	Protocolo, política e testes unitários apresentados
Viés/equidade	Riscos, critérios de segmentação e limitações documentados; auditoria real pendente
Versionamento da base/modelo	Proposta de versão e hash; patch local não publicado
Endpoint integrado	Endpoint de chat atual observado; nova rota preparada mas não integrada
Notebook, código, relatório e Model Card	Arquivos anexos ao pacote
Demonstração integrada	8 prints; três cenários de UI observados

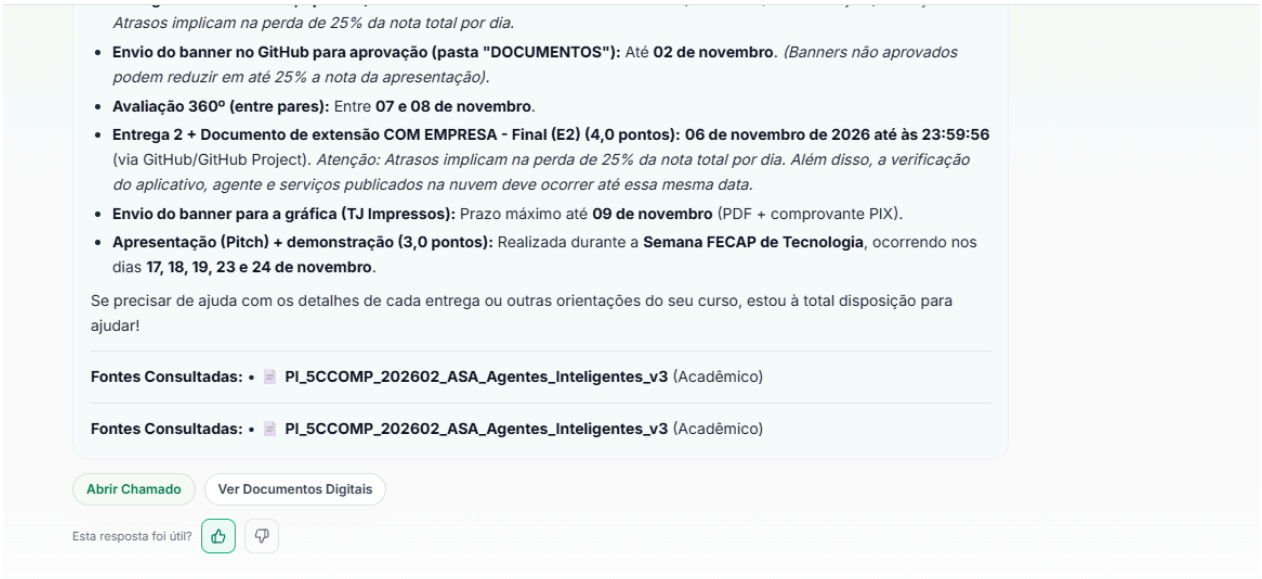
Apêndice A — Demonstração funcional com telas

EV-01 — Resposta sobre prazo do PI com documento indicado



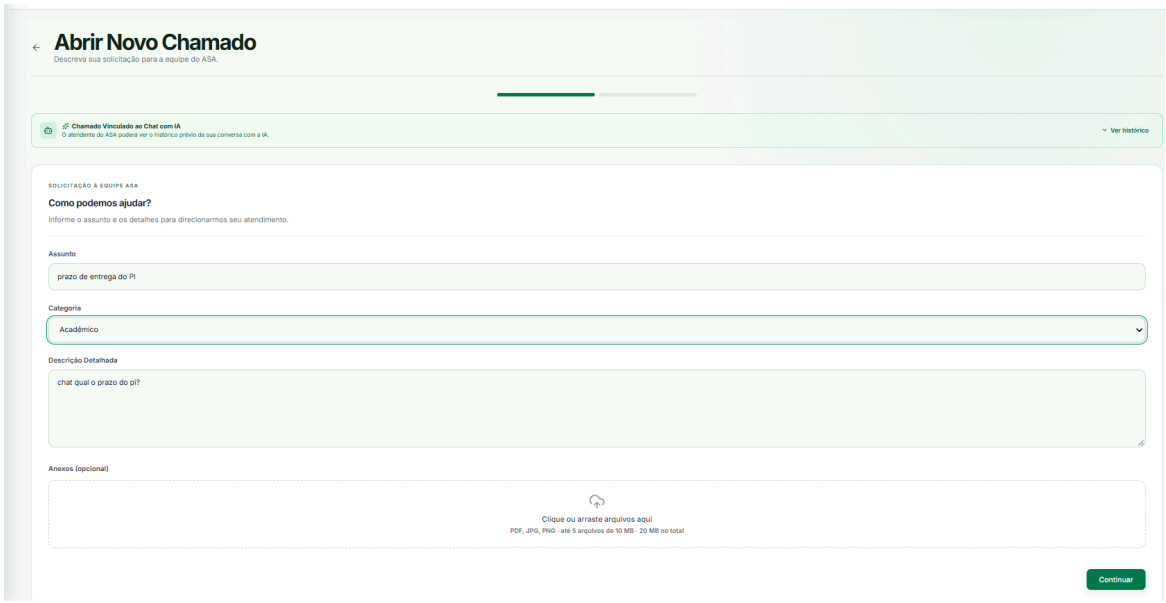
Resposta sobre prazo do PI com documento indicado. A data não foi cotejada com a norma original.

EV-02 — Fontes apresentadas no rodapé; nota-se duplicação e opções de encaminhamento.



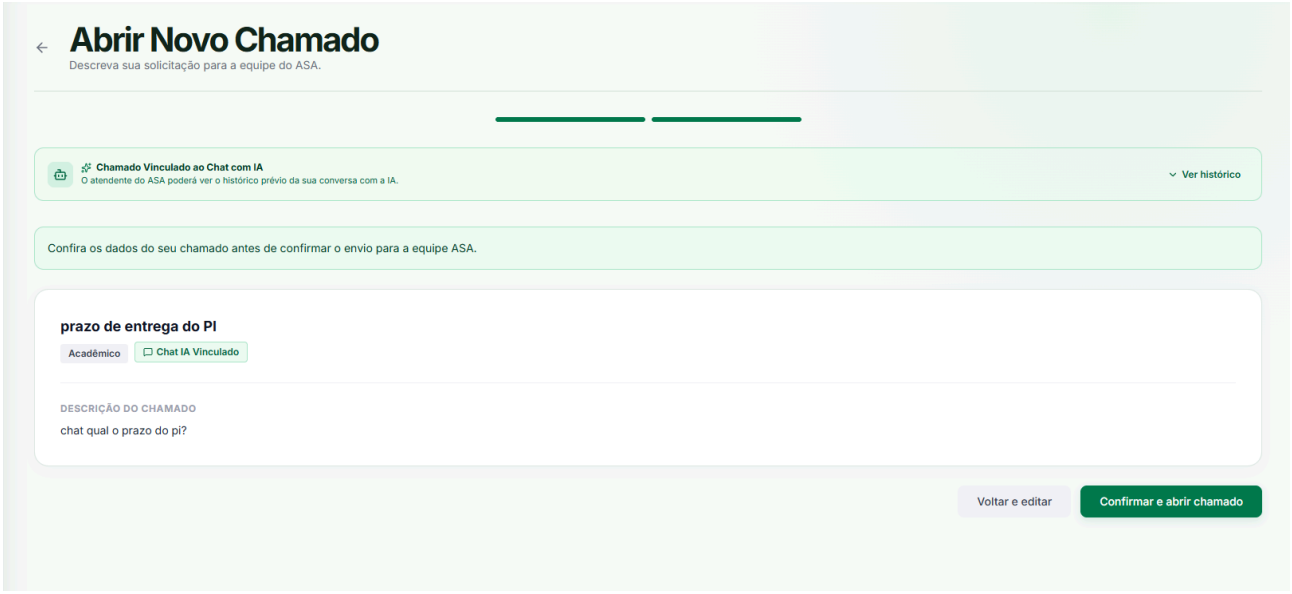
Fontes apresentadas no rodapé; nota-se duplicação e opções de encaminhamento.

EV-03 — Formulário de chamado iniciado a partir do chat, com vínculo à conversa.



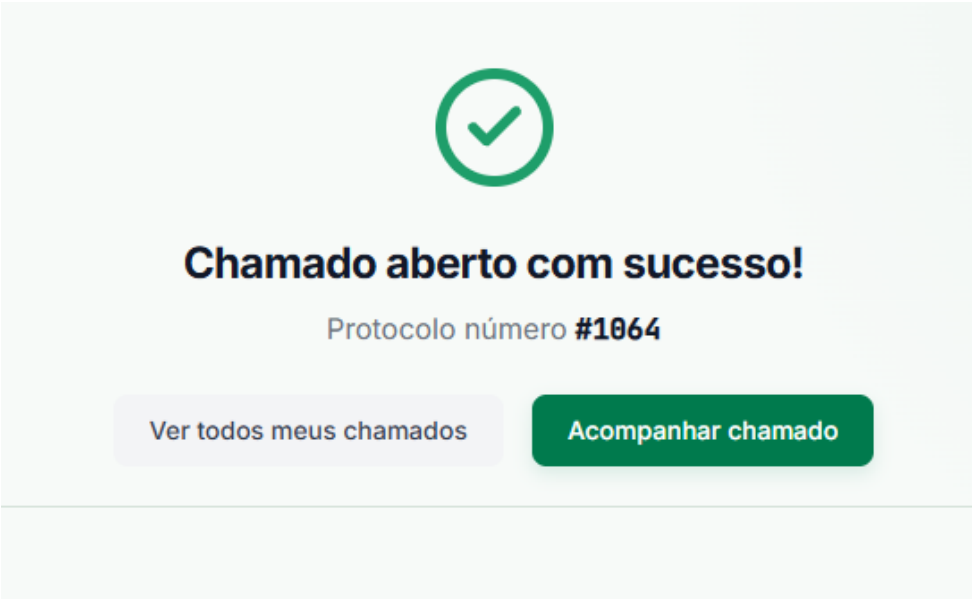
Formulário de chamado iniciado a partir do chat, com vínculo à conversa.

EV-04 — Revisão de categoria, assunto e origem antes da submissão.



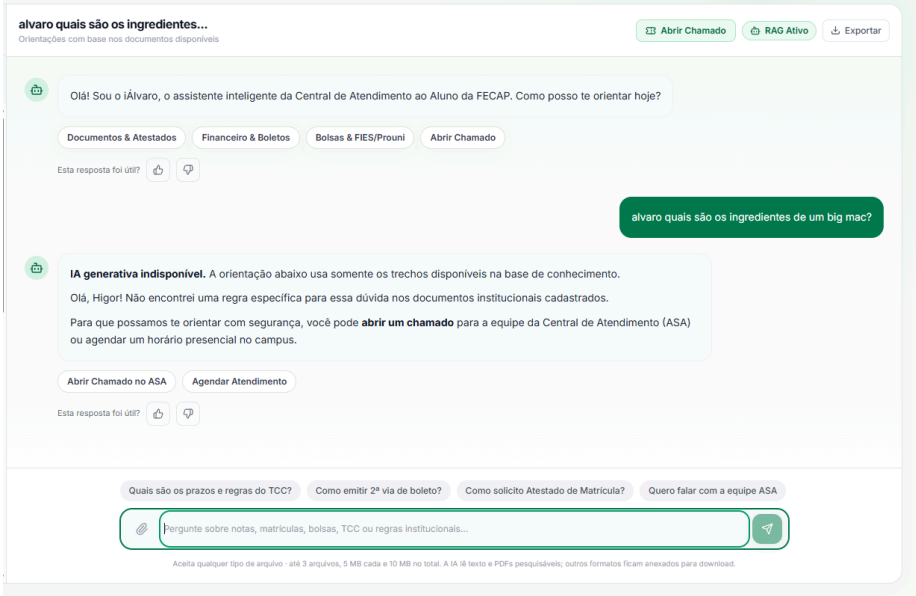
Revisão de categoria, assunto e origem antes da submissão.

EV-05 — Confirmação do protocolo #1064.



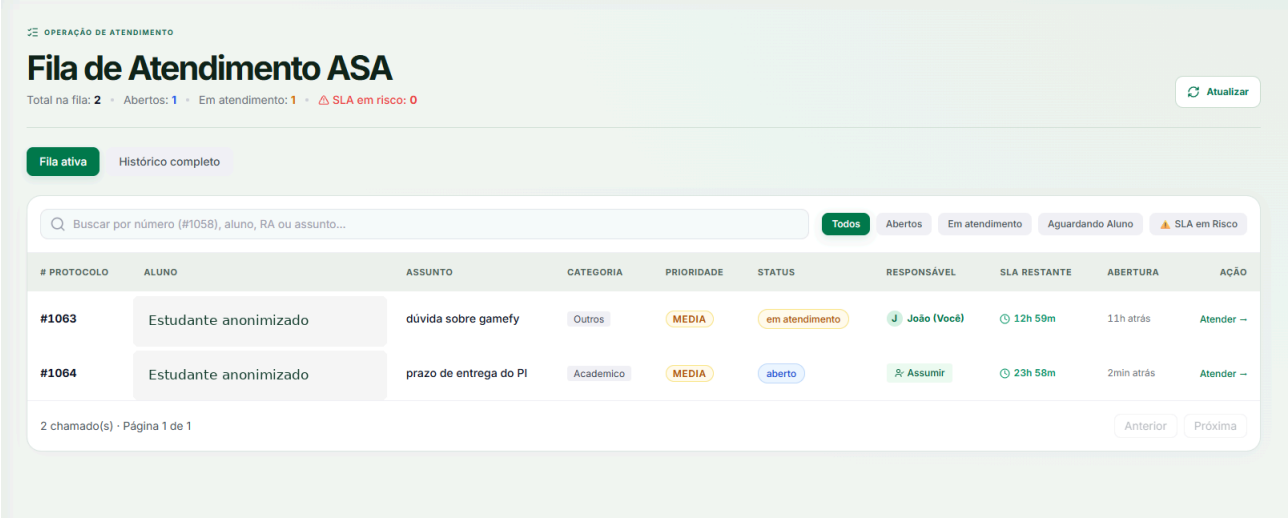
Confirmação do protocolo #1064.

EV-06 — Pergunta fora do domínio: fallback local se abstém e orienta contato humano.



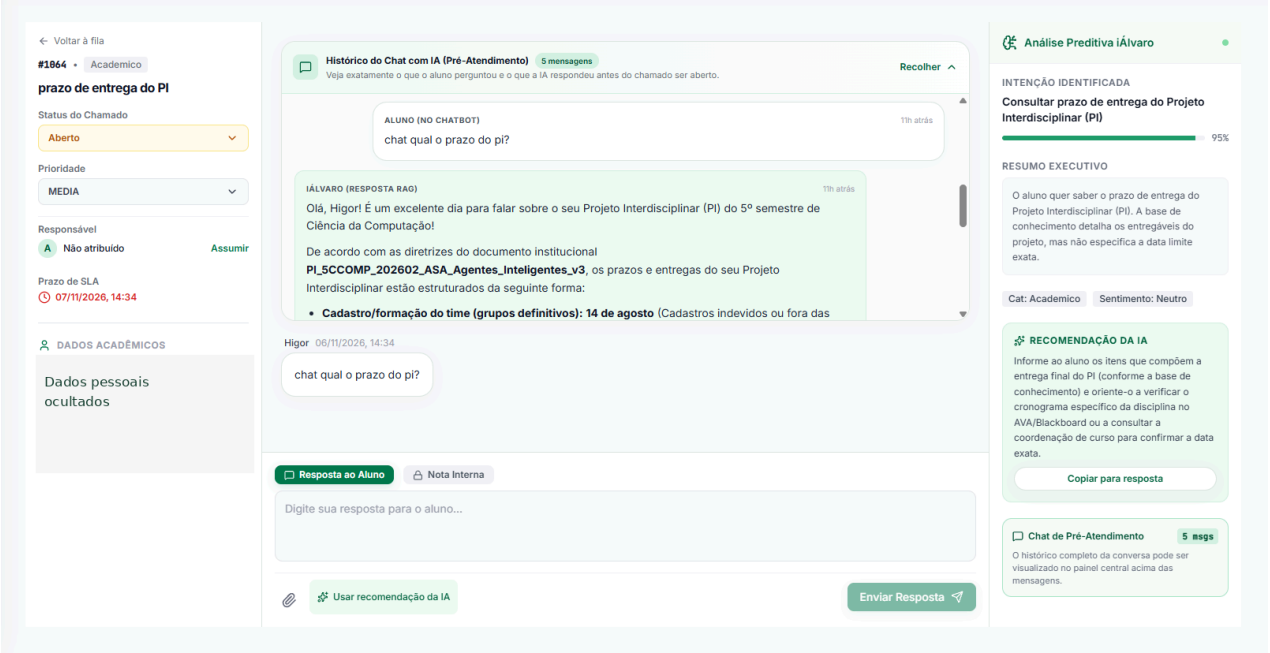
Pergunta fora do domínio: fallback local se abstém e orienta contato humano.

EV-07 — Chamado #1064 na fila de atendimento da equipe ASA.



Chamado #1064 na fila de atendimento da equipe ASA.

EV-08 — Tela do atendente exibe cinco mensagens e triagem; dados pessoais ocultados.



Tela do atendente exibe cinco mensagens e triagem; dados pessoais ocultados.